

Anteproyecto — Redes Neuronales y Aprendizaje Profundo

Curso: SI3014 — Redes Neuronales y Aprendizaje Profundo
Autoras: Mariana Valderrama Castañeda · Sara López Marín · Alexandra Hurtado David

1. Definición del Problema

Las enfermedades en plantas representan una de las principales causas de pérdidas agrícolas a nivel global. La detección temprana y precisa es crítica para contener infecciones antes de que se propaguen a cultivos completos. Sin embargo, el diagnóstico tradicional depende de inspección visual manual por parte de expertos, lo cual es costoso, lento y difícil de escalar en grandes extensiones de cultivo.

Tipo de tarea: Clasificación binaria de imágenes (sana vs. enferma).

Objetivo: Desarrollar un modelo de clasificación de imágenes basado en redes neuronales convolucionales (CNN) capaz de distinguir automáticamente entre hojas de plantas **sanas** y hojas **enfermas**, a partir de fotografías de hojas de tomate, papa y pimiento.

Una herramienta de diagnóstico visual automatizada permitiría a agricultores y técnicos detectar enfermedades en etapas tempranas, reducir el uso de pesticidas y optimizar las decisiones de intervención, contribuyendo a la seguridad alimentaria y la sostenibilidad de los cultivos.

2. Dataset

Dataset: PlantVillage (Hughes & Salathé, 2015), disponible públicamente en Kaggle.

Descripción

- **Total de imágenes:** 20,638
- **Clases originales (38):** múltiples enfermedades por especie de planta (tomate, papa, pimiento) más sus versiones sanas
- **Clases utilizadas (2):** colapsamos las 38 clases en clasificación binaria según el nombre de carpeta:
 - 0 — sana ← carpetas que contienen `healthy` en el nombre
 - 1 — enferma ← todas las demás

Distribución de clases:

- Sanas: ~15.6% del total
- Enfermas: ~84.4% del total
- **El dataset está desbalanceado**, lo que refuerza la necesidad de métricas como F1-score y Recall en lugar de Accuracy simple.

Justificación del enfoque binario: El objetivo del proyecto es la *detección temprana* de cualquier enfermedad, no su clasificación específica. Para el agricultor, la decisión relevante es saber si una planta requiere atención o no.

Entrada (X)	Etiqueta (y)	Modalidad
Imagen RGB de hoja de planta 0: sana / 1: enferma		
Imágenes		

3. Estrategia de División del Dataset

Conjunto	Proporción	# Imágenes aprox.
Entrenamiento	60%	~12,382
Validación	20%	~4,128
Prueba	20%	~4,128

- **Estratificación por clase:** sí, para mantener la proporción sana/enferma en cada split.
- **Justificación:** Con 20,638 imágenes se puede destinar un 40% a evaluación (20% val + 20% test) sin sacrificar la capacidad de entrenamiento. La estratificación es especialmente importante dado el desbalance 15.6% / 84.4%.

4. Preprocesamiento de Datos

Operaciones comunes (entrenamiento, validación y prueba):

- Redimensionamiento a 224×224 píxeles (RGB)
- Normalización con media y desviación estándar de ImageNet: `mean=[0.485, 0.456, 0.406]` , `std=[0.229, 0.224, 0.225]`

Augmentación (solo entrenamiento):

- Flip horizontal y vertical aleatorio
- Rotaciones aleatorias ($\pm 30^\circ$)
- Variación de brillo y contraste (`ColorJitter`)
- `RandomResizedCrop` con escala [0.8, 1.0]

Justificación: La augmentación es clave para mejorar la generalización y simular variaciones naturales de iluminación, ángulo y condiciones de campo. Sin augmentación en validación y prueba para evaluar de forma limpia y reproducible.

5. Arquitecturas Propuestas

Se comparan tres modelos con complejidad creciente, siguiendo las temáticas del curso.

Modelo 1 — CNN Baseline (from scratch)

Sirve como línea de referencia para cuantificar el beneficio de arquitecturas más complejas.

```
Input: 224×224×3
|
├─ Bloque Conv 1: Conv2D(32, 3×3) → BN → ReLU → MaxPool(2×2)
├─ Bloque Conv 2: Conv2D(64, 3×3) → BN → ReLU → MaxPool(2×2)
├─ Bloque Conv 3: Conv2D(128, 3×3) → BN → ReLU → MaxPool(2×2)
├─ Bloque Conv 4: Conv2D(256, 3×3) → BN → ReLU → MaxPool(2×2)
|
├─ GlobalAveragePooling2D
├─ Dense(256) → ReLU → Dropout(0.5)
└─ Dense(2) → Softmax      ← {sana, enferma}
```

Modelo 2 — CNN con Regularización Aumentada

Mismo backbone que el Modelo 1, con un clasificador más profundo y mayor regularización. Permite estudiar el efecto de Dropout doble y Weight Decay de forma aislada.

```
Input: 224×224×3   (con augmentación en entrenamiento)
|
├─ Mismos 4 bloques convolucionales
├─ GlobalAveragePooling2D
├─ Dense(256) → ReLU → Dropout(0.5)
├─ Dense(128) → ReLU → Dropout(0.3)
└─ Dense(2) → Softmax
```

Modelo 3 — Transfer Learning con ResNet18

Aprovecha representaciones preentrenadas en ImageNet y las adapta al dominio de hojas de plantas. Entrenamiento en dos fases: primero solo el clasificador, luego fine-tuning de `layer4`.

```
Pesos preentrenados (ImageNet) — ResNet18
    ↓
Backbone ResNet18 (congelado en Fase 1)
    ↓
GlobalAveragePooling
    ↓
Dense(256) → ReLU → Dropout(0.4)
    ↓
Dense(2) → Softmax      ← {sana, enferma}

Fine-tuning Fase 2: se descongela layer4 de ResNet18
```

Justificación: Los pesos preentrenados en ImageNet contienen detectores de bordes, texturas y estructuras que se transfieren bien al dominio de hojas de plantas, reduciendo el overfitting sin necesidad de grandes volúmenes adicionales de datos. ResNet18 ilustra además el concepto de skip connections visto en el curso.

6. Estrategia de Entrenamiento

Hiperparámetro	Modelo 1 (Baseline)	Modelo 2 (Regularizado)	Modelo 3 Fase 1	Modelo 3 Fase 2
Loss	CrossEntropyLoss	CrossEntropyLoss	CrossEntropyLoss	CrossEntropyLoss
Optimizer	Adam	Adam	Adam	Adam
Learning rate	1e-3	1e-3	1e-4	1e-5
Batch size	32	32	32	32
Épocas máx.	30	30	10	10
Dropout	0.5	0.5 / 0.3	0.4	0.4
Weight decay	—	1e-4	1e-4	1e-4

Hardware: NVIDIA Tesla T4 (15.6 GB VRAM) · Kaggle Notebooks · PyTorch · CUDA.

7. Estrategia de Validación

Métrica	Justificación
F1-score (macro)	Métrica principal — robusta ante el desbalance de clases (15.6% / 84.4%)
Accuracy	Referencia general
Recall (clase enferma)	Crítico: un falso negativo (planta enferma no detectada) puede propagar la infección
AUC-ROC	Evalúa la capacidad discriminativa del modelo

- **Early stopping:** paciencia de 10 épocas sobre `val_F1`
- **Criterio de selección:** mayor F1-score en validación
- Se cargan automáticamente los pesos del mejor epoch al detenerse

8. EDA Inicial

- Distribución de clases (sana vs. enferma) por split — evidencia el desbalance 15.6% / 84.4%
- Visualización de ejemplos por clase (mínimo 5 imágenes por categoría)
- Histogramas de distribución de píxeles por canal (R, G, B) — confirma pertinencia de normalización ImageNet

Se incluirán al menos 2 visualizaciones: distribución de clases y ejemplos representativos de hojas sanas y enfermas.

9. Pregunta de Investigación y Objetivo

Pregunta de investigación:

¿Puede una red neuronal convolucional entrenada con imágenes de hojas de plantas distinguir entre plantas sanas y enfermas, y en qué medida mejora el desempeño al incorporar transfer learning frente a entrenar desde cero?

Objetivo: Comparar el desempeño de tres arquitecturas CNN de complejidad creciente (baseline, regularización aumentada, transfer learning con ResNet18) para la detección binaria de enfermedades en hojas de plantas, evaluando la mejora en F1-score y Recall sobre el conjunto de prueba.

10. Referencias

1. Hughes, D., Salathé, M. (2015). An open access repository of images on plant health. *arXiv:1511.08060*. <https://arxiv.org/abs/1511.08060>
2. He, K., Zhang, X., Ren, S., Sun, J. (2016). Deep Residual Learning for Image Recognition. *CVPR 2016*. <https://arxiv.org/abs/1512.03385>
3. Mohanty, S.P., Hughes, D., Salathé, M. (2016). Using Deep Learning for Image-Based Plant Disease Detection. *Frontiers in Plant Science*, 7, 1419.
4. Saleem, M.H., Potgieter, J., Arif, K.M. (2019). Plant Disease Detection and Classification by Deep Learning. *Plants*, 8(11), 468. <https://doi.org/10.3390/plants8110468>
5. Martínez Vargas, J.D. (2026). SI3014 — Redes Neuronales y Aprendizaje Profundo [Material de curso]. GitHub. <https://github.com/jdmartinev/SI3014---Redes-Neuronales-y-Aprendizaje-Profundo>